



**TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA
PROJELERİ DESTEKLEME PROGRAMI**

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1.Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Buğra MUHÇI
Araştırma Önerisinin Başlığı: Uç Cihazlarda Zamansal Grafik Sinir Ağları ile Siber Saldırı Tespiti
Danışmanın Adı Soyadı: Dr. Öğr. Üyesi Burcu YILMAZEL
Araştırmanın Yürütüleceği Kurum/Kuruluş: Eskişehir Teknik Üniversitesi

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Özet

Bu proje, ağ trafiğindeki saldırıları zamansal örüntülere (temporal patterns) dayanarak tespit edebilen grafik sinir ağı(Graph Neural Network – GNN) tabanlı bir model geliştirmeyi amaçlamaktadır. Günümüzde kullanılan klasik makine öğrenmesi (machine learning) ve statik derin öğrenme (deep learning) yaklaşımları, trafiği yalnızca tek bir zaman diliminde değerlendirerek saldırıların zaman içindeki davranışsal değişimlerini yakalayamamaktadır. Bu durum, “slow-burn” olarak bilinen SSH brute-force, SQL Injection ve XSS gibi saldırıların tespitinde başarıyı düşürmektedir.

Bu sorun için ağ trafiği zamansal grafik (temporal graph) biçiminde temsil edilerek hem yapısal (structural dependencies) hem de zamansal bağımlılıklar (temporal dependencies) aynı anda öğrenilecektir. Modelin çekirdeğini Zamansal Graf Dikkat Ağı (Temporal Graph Attention Network – TGAT), Graf Konvolüsyonel Uzun Kısa Süreli Bellek Ağı (Graph Convolutional LSTM – GCLSTM) ve bu iki yapının hibrit bileşimi oluşturacaktır. Böylece kısa ve uzun vadeli saldırı örüntüleri birlikte yakalanabilecektir.

Bilimsel yöntem olarak, LSNM 2024 veri kümesi (yaklaşık 6,5 milyon kayıt, 15 saldırı sınıfı) üzerinde eğitim gerçekleştirilecek; veri dengesizliği Sentetik Azınlık Örneklem Tekniği (SMOTE) ile giderilecektir. Eğitim GPU destekli bir sistemde yapılacak, çıkarım (inference) işlemleri Raspberry Pi 5 üzerinde yürütülecektir. Bu cihaz, düşük maliyetli uç (edge) donanımların davranışını temsil eden bir sinama ortamı (testbed) sağlayacaktır. Performans, doğruluk (accuracy), makro-F1, kesinlik (precision), duyarlılık (recall) ve ROC-AUC metrikleriyle değerlendirilecektir.

Proje yönetimi üç aşamada yürütülecektir: (1) veri hazırlama ve graf temsili, (2) TGAT, GCLSTM ve hibrit modellerin geliştirilmesi, (3) uç cihaz üzerinde optimizasyon (quantization) ve test. Sistem, izole bir laboratuvar ortamında (testbed) doğrulanacak; tüm kod ve yapılandırmalar açık kaynak biçimde doküman edilecektir.

Sanayi odaklı çıktı olarak Raspberry Pi üzerinde çalışan bir akıllı güvenlik modülü (intelligent security module) prototipi geliştirilecektir. Bu modül, banka altyapıları ve üniversite bilişim merkezleri gibi çok sayıda uç birime sahip kurumsal yapılarda gerçek zamanlı saldırı tespiti (real-time intrusion detection) sağlayacaktır. Düşük donanım gereksinimi, sistemi Türkiye'nin yerli siber güvenlik ekosistemine entegre edilebilir hale getirecektir.

Yaygın etki olarak proje, yerli siber güvenlik teknolojilerinin gelişimine katkı sağlayacak; ayrıca öğrenciler ve araştırmacılar için graf tabanlı yapay zeka sistemlerine dair açık kaynak bir eğitim materyali oluşturacaktır. Sistem, pfSense / Suricata entegrasyonu ile saha testlerine genişletilerek ticarileşmeye aday (commercially viable) bir ürün haline gelebilir.

Bu yönleriyle proje, Birleşmiş Milletler Sürdürülebilir Kalkınma Amaçları (SKA 9: Sanayi, Yenilikçilik ve Altyapı) ile uyumlu olup, Türkiye'de yerli, ölçeklenebilir ve sürdürülebilir siber güvenlik altyapılarının geliştirilmesine katkı sunacaktır.

Anahtar Kelimeler: Siber Güvenlik, Zamansal Grafik Sinir Ağları, Yapay Zeka Tabanlı Güvenlik Sistemleri, Saldırı Tespiti, Raspberry Pi

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Siber saldırıların karmaşıklığının artması, IoT ve uç (*edge*) cihaz yoğunluklu ağ topolojilerinin yaygınlaşması ve modern tehdit vektörlerinin zaman içinde evrilerek ilerlemesi, geleneksel saldırı tespit sistemlerinin etkinliğini sınırlamaktadır. Güncel raporlar, veri ihlallerinin kurumsal yapılara ciddi mali yükler getirdiğini ve saldırıların büyük bölümünün erken evrede tespit edilemediğini göstermektedir (IBM, 2024; Cobos et al., 2024). Literatürde yaygın olarak kullanılan klasik makine öğrenmesi modelleri, ağ trafiğini bağımsız örnekler olarak ele almakta; derin öğrenme tabanlı yöntemler ise saldırıların zaman serisi içindeki örüntülerini yakalayabilseler de ağınlı ilişkisel/topolojik yapısını yeterince temsil edememektedir (Ring et al., 2019; Khraisat et al., 2019). Son yıllarda grafik sinir ağları (Graph Neural Network - GNN) saldırı tespit araştırmalarında önemli bir gelişme alanı haline gelmiş olsa da mevcut çalışmaların büyük bölümü statik grafik yaklaşımıyla sınırlı kalarak ağınlı zaman içinde değişen yapısını modellememektedir. Öte yandan, ağ trafiğinin zamanla değişen yapısını modelleyen zamansal grafik sinir ağları (Temporal GNN - TGNN), öneri sistemleri, sosyal ağlar ve finans alanlarında başarıyla uygulanmış olmalarına karşın siber saldırı tespitine yönelik kullanımları henüz oldukça sınırlıdır (Rossi et al., 2020; Sankar et al., 2020). Diğer taraftan, TGNN yaklaşımlarının, ağ güvenliği gibi dinamik ortamlarda yüksek performans sağlama potansiyeli bulunmaktadır (Söhner et al., 2020). Ayrıca mevcut TGNN modellerinin kaynak kısıtlı uç cihazlarda çalışabilirliği literatürde henüz sistematik olarak incelenmemiştir. Bu durum modern kurumsal yapılardaki yüzlerce uç noktada konumlanabilecek siber saldırı çözümlerinin geliştirilmesini zorlaştırmaktadır.

Bu noktadan hareketle, söz konusu literatür boşluğuna yönelik olarak, önerilen araştırma projesinin temel amacı, TGNN kullanarak ağ trafiğinde meydana gelen saldırı örüntülerini hem yapısal (*graph-based*) hem de zamansal (*temporal*) boyutlarıyla modelleyebilen, uç cihazlarda çalıştırılabilir bir saldırı tespit prototipi geliştirmektir. Projede özellikle iki ileri düzey TGNN mimarisi — Temporal Graph Attention Network (TGAT) (Xu et al., 2020; Dai et al., 2024) ve Graph Convolutional LSTM (GCLSTM) (Seo et al., 2018; Seo et al., 2018; Pareja et al., 2020) — temel olarak kullanılacak; ayrıca bu iki yapının birleşiminden oluşan özgün bir hibrit TGAT–GCLSTM modeli tasarlanacaktır.

Bu yaklaşım, son yıllarda yapılan çalışmalarda önerilen gerçek zamanlı GNN tabanlı trafik analiz sistemlerinden esinlenmiştir (İbrahim et al., 2025; Bharathi & Raj, 2025). Özellikle “*Real-Time Graph Neural Network for Malicious Traffic Detection*” çalışması (İbrahim et al., 2025), ağ trafiği üzerindeki saldırı örüntülerinin GNN ile etkin biçimde modellenebileceğini göstermiştir. Ancak önerilen bu proje, doğrudan canlı ağ altyapılarına değil, laboratuvar ortamında test edilecek prototip bir sistemin geliştirilmesine odaklanmaktadır. Böylece, bu tür modellerin gerçek zamanlı uygulamalara geçiş öncesi performans, ölçeklenebilirlik ve gecikme (*latency*) açısından nasıl davrandığı bilimsel olarak değerlendirilecektir.

Proje, TGAT ve GCLSTM mimarilerini temel alarak zamana bağlı saldırı örüntülerini (*temporal attack patterns*) öğrenmeyi hedeflemektedir (Xu et al., 2020; Seo et al., 2018). TGAT mimarisi, zamansal bağımlılıkları zaman kodlama (*time-encoding*) katmanlarıyla yakalarken (Dai et al., 2024; Xu et al., 2020), GCLSTM modeli LSTM hücreleriyle ardışık graf temsillerini zamansal olarak işlemektedir (Pareja et al., 2020).

Elde edilecek model, LSNM2024 veri setinde (Al-Haija et al., 2025) yer alan 15 farklı saldırı sınıfı üzerinde eğitilecek; hem yüksek doğruluk (*accuracy*) hem de yüksek F1–makro skorlarıyla dengesiz saldırı sınıflarında (*imbalanced classes*) etkili performans gösterecek bir modelin geliştirilmesi hedeflenecektir.

Eğitim süreci GPU destekli bir bilgisayarda (NVIDIA RTX 3060 veya Apple M3 GPU) yürütülecek, çıkarım (*inference*) işlemi ise tek bir Raspberry Pi 5 (8GB) üzerinde gerçekleştirilecektir. Bu cihaz, ağa takılı bir

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

proxy/firewall bileşeni olarak çalışacak; belirli bir eşik (threshold) değeri (örneğin, aynı sınıfta 10 yüksek güven (confidence ≥ 0.95) tespiti 1 saatlik pencerede oluşması) aşıldığında Alarm/Collect mekanizması devreye girecek ve kullanıcıdan internet bağlantısını kesip kesmeme onayı istenecektir.

Veri dengesizliği, SMOTE (*Synthetic Minority Over-sampling Technique*) yöntemiyle giderilecek; azınlıkta kalan saldırı sınıflarına sentetik örnekler eklenerek modelin genel öğrenme dengesi sağlanacaktır (Chawla et al., 2002). Bu yapı, hem zamansal hem topolojik bilgiye dayalı hibrit bir saldırı tespit modeli oluşturacaktır.

Projenin özgün ve yenilikçi yönleri;

- TGNN mimarisinin, siber saldırı tespitine yönelik sınırlı sayıda çalışmalardan biri niteliğindedir.
- Proje kapsamında, TGAT ve GCLSTM mimarilerinin yanı sıra, bu iki yapının birleşiminden oluşacak özgün bir hibrit TGAT–GCLSTM modeli tasarlanacaktır. Bu modellerin birleşiminden oluşan hibrit TGAT–GCLSTM mimarisi, literatürde siber güvenlik bağlamında ele alınmamış olup projenin yenilikçi yönlerinden biridir.
- Önerilen hibrit mimari teknolojik yenilik açısından da ayrıca önemlidir. Ağ trafiğini kaydırmalı zaman pencereleri ile dinamik bir grafik olarak temsil eden ve saldırıların zaman içindeki evrimini TGAT'in zaman kodlama (time-encoding) mekanizmalarıyla ve GCLSTM'nin ardışık grafik işleme kapasitesiyle yakalayan yeni bir yaklaşım sunmaktadır. Bu yapı, klasik saldırı tespit sistemlerinde tespit edilmesi güç olan, çoğunlukla gözden kaçan "slow-burn", çok aşamalı (multi-stage) ve lateral movement tarzı saldırıların erken evrede tanınmasına imkan tanıyarak gerçek zamanlı sistemlerde daha yüksek tespit doğruluğu öngörmektedir (Ibrahim et al., 2025). Bu yönüyle proje, statik GNN tabanlı saldırı tespit sistemlerinin sınırlamalarını aşarak literatürdeki en güncel eğilimi ileri taşımaktadır.
- Mevcut araştırmalar TGAT, GAT, GCN ve LSTM tabanlı saldırı tespit modellerini genellikle tekil modeller üzerinden değerlendirmekte olup (Bharathi & Raj, 2025; Ibrahim et al., 2025), çoklu TGNN mimarisinin sistematik karşılaştırmalı analizi literatürde bulunmamaktadır. Bu bağlamda proje, üç farklı modelin doğruluk – TGAT, GCLSTM, TGAT–GCLSTM – F1-makro, gecikme ve bellek kullanımı açısından karşılaştırılmasıyla hangi zamansal GNN mimarisinin uç cihazlara en uygun olduğunu deneysel olarak ortaya koyacak ilk çalışma olma potansiyeline de sahiptir.

Proje ayrıca teknolojik olgunluk ve uygulama pratiği açısından da önemli katkılar sunmaktadır.

- TGNN modellerinin kaynak kısıtlı uç cihazlarda çalışabilirliği üzerine literatürde yok denecek kadar az çalışma mevcuttur.
- Geliştirilecek TGAT–GCLSTM tabanlı modeller, GPU destekli bir bilgisayarda eğitilecek; çıkarım süreci ise düşük maliyetli bir uç cihaz olan Raspberry Pi 5 üzerinde test edilecektir. Bu sayede TGNN mimarilerinin uç cihazlarda gerçek kullanım senaryoları açısından performans, ölçeklenebilirlik, gecikme ve bellek tüketimi gibi faktörler ilk kez kapsamlı biçimde analiz edilecektir.
- Proje, düşük maliyetli uç cihazlar (ör. Raspberry Pi 5) üzerinde çalışabilecek şekilde optimize edilmiş yapay zeka tabanlı saldırı tespit modülü geliştirmektedir. Dolayısıyla model, post-training quantization, pruning ve pencere-temelli optimizasyonlar gibi tekniklerle hafifletilerek uç cihazlarda uygulanabilir hâle getirilecektir. Bu sayede model, yüksek donanım gereksinimi olmadan ağ trafiğini gerçek zamanlı olarak analiz edebilecektir. Bu özellikler, piyasadaki mevcut saldırı tespit çözümlerinin büyük bölümünün yalnızca sunucu veya bulut tarafında çalışabildiği düşünüldüğünde, projeyi endüstriyel olarak güçlü ve farklılaşan bir konuma taşımaktadır.
- Proje çıktısı, pfSense, Suricata ve benzeri güvenlik duvarı/platformlarıyla entegrasyona uygun bir karar destek modülü sunacak şekilde tasarlanacak olup; bankacılık, üniversite ağları, kamu kurumları ve geniş ölçekli IoT altyapıları gibi çok sayıda uç birime sahip yapılarda düşük maliyetli, yerli ve ölçeklenebilir bir saldırı tespit modülü olarak kullanılabilir niteliktedir. Bu yönüyle proje, üniversite–sanayi iş birliğine doğrudan katkı sağlamakta ve ülkemizde geliştirilen yerli siber güvenlik teknolojilerinin artmasına destek olmaktadır.

Sonuç olarak proje; (i) literatürdeki statik GNN tabanlı saldırı tespit sistemi eksikliklerini gideren, (ii) zamansal GNN'leri siber güvenlik bağlamına uyarlayan, (iii) gerçek dünya kurumsal ağlarında uygulanabilir ve uç cihazlarda çalışabilir bir tespit sistemi geliştiren bilimsel ve endüstriyel değeri yüksek bir çıktıyı hedeflemektedir. Geliştirilecek çözüm, sanayi ortağı siber güvenlik firmasının ürün portföyünde kullanılabilecek, üniversite

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

kampüsü, finans kurumları ve geniş ölçekte dağıtık IoT altyapılarında uygulanabilecek yerli, yenilikçi ve ticarileştirilebilir bir teknoloji niteliği taşımaktadır.

Bu yenilikçi bileşenler, Türkiye Cumhuriyeti 12. Kalkınma Planı (2024-2028) (CSBB, 2023), 2030 Sanayi ve Teknoloji Stratejisi (STB, 2025a; 2025b) ile OTAĞ Sonuç Raporu (STB, 2025c)'nde önceliklendirilen “Siber Güvenlik”, “Yapay Zeka Tabanlı Sistemler”, “Akıllı ve Bağlantılı Güvenlik Altyapıları” ve “Edge/IoT Güvenliği” başlıkları ile güçlü bir uyum içindedir. Proje, söz konusu planların öngördüğü şekilde yüksek katma değerli yerli teknolojilerin geliştirilmesi, kritik güvenlik bileşenlerinin milli imkanlarla üretilmesi ve yapay zeka tabanlı siber savunma çözümlerinin yaygınlaşması ve edge tabanlı akıllı güvenlik modülleri alanında sanayiye yönelik yeni bir Ar-Ge yaklaşımı kazandırılması hedeflerine doğrudan katkı sunmaktadır. Ayrıca proje, Birleşmiş Milletler Kalkınma Programı, Sürdürülebilir Kalkınma Amaçları (SKA)'ndan, “SKA 9: Sanayi, Yenilikçilik ve Altyapı” hedefleri ile de doğrudan uyumludur (UNDP, 2025).

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Bu proje, siber saldırı tespitinde TGNN kullanan bir yaklaşım önermektedir. TGAT ve GCLSTM mimarileri temel alınarak, ağ trafiği üzerindeki saldırı örüntülerinin hem yapısal hem de zamansal bağımlılıklarını aynı anda öğrenebilen gelişmiş bir tespit mekanizması geliştirilecektir. Projede ağ trafiği, zaman pencerelerine bölünerek graf biçiminde temsil edilerek; saldırıların yalnızca tek bir anda değil, zaman içindeki davranış evrimleri de modellenmesi sağlanacaktır (Xu et al., 2020).

Bu proje, üç temel hedefe ve bu hedeflere ulaştıracak alt-hedeflere odaklanmaktadır:

- **Zamansal saldırı örüntülerinin grafik düzeyinde modellenmesi:** Ağ trafiğinin zaman damgalı akışlarının bir dinamik grafik olarak temsil edilmesi ve TGAT ile GCLSTM mimarileri aracılığıyla hem yapısal hem de zamansal bağımlılıkların eş zamanlı öğrenilmesi hedeflenmektedir. Bu sayede çok aşamalı (*multi-stage*) saldırılar, yanal hareketler (*lateral movement*) ve botnet gibi zamanla evrilen tehditlerin erken tespiti sağlanacaktır.
 - **Zamansal farkındalık:** TGAT (Dai et al., 2024; Xu et al., 2020) mimarisi sayesinde saldırı paternlerinin zaman kodlamaları (time-encoding) öğrenmekte, klasik GNN yaklaşımlarına göre daha yüksek doğruluk etmeye çalışılacaktır (Bharathi & Raj, 2025; Söhner et al., 2020).
- **TGAT ve GCLSTM tabanlı yeni bir hibrit mimari geliştirilmesi:** Literatürde siber saldırı tespitine özel hibrit TGNN mimarisi bulunmamaktadır. Proje kapsamında, *temporal attention* ve *graph-convolutional recurrent* yapılarını bir araya getirerek saldırı örüntülerini daha yüksek doğrulukla tanıyabilen özgün bir TGAT–GCLSTM modelinin geliştirmeyi amaçlamaktadır.
 - **Model karşılaştırmalı değerlendirme:** Çalışma kapsamında TGAT, GCLSTM ve bu iki yapının hibrit versiyonu ayrı ayrı eğitilecek; üç modelin performansı doğruluk (accuracy), F1-makro, gecikme (latency) ve bellek kullanımı açısından karşılaştırılarak en yüksek verim sağlayan yapı seçilecektir. Bu yaklaşım, literatürdeki tek-model odaklı çalışmalardan (ör. Bharathi & Raj, 2025; Ibrahim et al., 2025) farklı olarak, hangi mimarinin edge cihazlarda daha uygun olduğunu deneysel olarak ortaya koyacaktır.
- **Geliştirilen modelin uç cihazlarda çalışabilecek şekilde optimize edilmesi:** Siber güvenlik şirketleri için en kritik gereksinimlerden biri, merkezi sistemlere yük getirmeden uç cihazlarda çalışabilen hafif, düşük gecikmeli, gerçek zamanlı saldırı tespit çözümleri geliştirmektir. Bu nedenle proje, geliştirilen TGNN modellerinin Raspberry Pi 5 gibi kaynak kısıtlı uç cihazlarda çalıştırılabilmesi amacıyla model sıkıştırma, kuantizasyon, pencereleme stratejileri ve CPU tabanlı hızlandırma yöntemleri üzerinde duracaktır (Kose et al., 2024; Tailor et al., 2020). Bu yönüyle proje sanayinin doğrudan ihtiyaç duyduğu, ölçeklenebilir bir siber saldırı tespit çözümüne katkı sunmayı hedeflemektedir.

- *Edge-AI optimizasyonu*: Model, post-training quantization ve model pruning adımlarıyla Raspberry Pi'de düşük gecikmeli (latency) çalışacak şekilde optimize edilecektir (Al-Haija et al., 2025).
- *Gerçek zamanlı entegrasyon*: Model çıktıları, pfSense ve Suricata gibi yaygın güvenlik duvarı altyapılarına entegre edilebilecek biçimde tasarlanacaktır (Al-Haija et al., 2024a).

Projenin sanayi odaklı hedefleri ise,


- *Uç cihazlarda çalışabilir bir prototip geliştirme*: Model, düşük maliyetli uç cihazlar (ör. Raspberry Pi 5, mini-firewall sistemleri) üzerinde çalışabilir hale getirilerek, banka altyapıları ve üniversite bilişim merkezleri gibi çok sayıda uç birime sahip kurumsal yapılarda kullanılabilir ve ölçeklenebilir bir çözüm sunabilecektir.
- *Ürünleşme potansiyeline sahip bir teknoloji ortaya koyma*: Geliştirilen model, siber güvenlik şirketlerinin *firewall/proxy/endpoint* çözümlerine eklenilebilir bir "uç kaynak saldırı tespit modülü" için temel oluşturacaktır.
- *Gerçek zamanlı sistemlere geçiş öncesi teknik riskleri azaltmak*: Laboratuvar testbed'i sayesinde hangi mimarilerin operasyonel ortama uygun olduğu, hangi koşullarda performans kaybı yaşandığı net şekilde ortaya konacaktır.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Bu projede saldırı tespiti, ağ trafiğinin hem zamansal hem de yapısal bağımlılıklarını bütünlük biçimde modelleyen **zamansal grafik sinir ağı (Temporal Graph Neural Network, TGNN)** yaklaşımı temel alınarak gerçekleştirilecektir. Yöntem, literatürdeki statik grafik modellerinin sınırlılıklarını aşmak üzere tasarlanmış olup Şekil 1'de gösterilen beş temel aşamadan oluşmaktadır: (1) veri hazırlama ve dengeleme, (2) grafik temsili ve zaman penceresi dönüşümü, (3) model geliştirme ve eğitim, (4) laboratuvar testbed'i üzerinde çıkarım testleri.



Şekil 1. Proje sürecinin genel aşamaları.

1. Veri Hazırlama ve Dengeleme


Çalışmada kullanılacak LSNM2024 veri seti (Al-Haija et al., 2025), zaman damgalı ağ olayları (network events) içeren ve 15 farklı saldırı türü ile normal trafiği kapsayan çok boyutlu bir kayıt yapısı sunmaktadır (Şekil 2).

Veri seti, toplam 60'tan fazla akış/paket tabanlı özellik içermektedir. Bu çok protokollü ve zaman damgalı yapı,

hem zaman serisi analizi hem de grafik tabanlı saldırı tespit modelleri için oldukça uygundur. Veri setindeki başlıca özellikler şöyledir:

- kaynak–hedef adresleri,
- protokol bilgileri (TCP/UDP/ICMP/ARP/NTP/HTTP),
- paket uzunluğu,
- TCP bayrakları (SYN/ACK/RST),
- DNS/HTTP alanları ve

Veri setinde saldırı sınıfları arasında belirgin bir dengesizlik bulunduğundan SMOTE (Synthetic Minority Over-sampling Technique) (Chawla et al., 2002) uygulanacaktır. SMOTE yalnızca düşük temsil edilen saldırı türlerine uygulanacak; bu sayede sınıf önyargısı azaltılarak tüm modellerin dengesiz veriye karşı daha kararlı öğrenmesi sağlanacaktır. Her saldırı türü için örnek dağılımı analiz edilip SMOTE yalnızca az temsil edilen sınıflara uygulanacaktır (ör. Exploit-FTP, XSS, SQL Injection).



Şekil 2. LSM2024 veri setindeki saldırı türlerinin dağılımı.

Bu aşamada veri temizleme, özellik seçimi, SMOTE ile sınıf dengelenmesi ve zaman damgalı ön işlem adımları tamamlanacaktır.

2. Grafik Temsili ve Zaman Penceresi Dönüşümü

Ağ trafiği, her biri belirli bir zaman aralığını temsil eden dinamik grafik bellek kayıtları (graph snapshots) hâline getirilecektir. Bu yaklaşım, zaman boyunca değişen saldırı örüntülerinin yakalanmasını mümkün kılar (Xu et al., 2020).

2.1. Zaman Penceresi Dönüşümü: Veri, farklı pencerelere bölünecektir (ör. 1 sn, 5 sn, 10 sn). Her pencere, zaman içindeki tüm olaylardan oluşan bir grafik olarak işlenecektir.

2.2. Grafik Temsili: Grafik dizilimi, düğümler, kenarlardan oluşacaktır.


- Düğümler (Nodes): IP adresleri veya IP:port birleşimleri
- Kenarlar (Edges): zaman damgalı akışlar
- Düğüm özellikleri: toplam paket sayısı, ortalama paket boyutu, protokol tipi, inter-arrival time
- Kenar özellikleri: yunusul bayt oranı, RTT, bağlantı sıklığı, SYN/ACK oranı, akış yönü

Bu şekilde oluşturulan grafik dizileri (*graph sequences*) hem TGAT hem de GCLSTM için uygun bir girdi oluşturacaktır (Seo et al., 2018; Pareja et al., 2020).

3. Model Tasarımı, Öğrenme Mimarisi ve Eğitim Süreci

Ağ saldırı türleri farklı zamansal ve yapısal özellikler gösterdiğinden, proje kapsamında üç farklı model mimarisi değerlendirilecektir: TGAT (Temporal Graph Attention Network), GCLSTM (Graph Convolutional LSTM) ve bu iki mimarinin birleşiminden oluşan hibrit TGAT–GCLSTM modeli. *Zamanla değişen ve statik grafik türlerinin karşılaştırılması.*

- TGAT: Zaman damgalı düğüm ve kenarları çoklu başlık (multi-head) dikkat mekanizması ile işler. Zaman farklarını (Δt) time-encoding katmanıyla öğrenerek hem yapısal hem zamansal bağımlılıkları aynı anda temsil eder; TGAT proje kapsamında primary backbone olarak öncelikli test edilecektir (Dai et al., 2024; Xu et al., 2020).
- GCLSTM: Her zaman adımındaki grafi konvolüsyonel olarak işler; LSTM hücresi aracılığıyla geçmiş zamandaki durumu bir sonraki adıma aktarır. GCLSTM, ardışık graf bellek kayıtları zamansal olarak modellemede etkili bir yapı sunar ve EvolveGCN benzeri dinamik-graf yaklaşımlarıyla ilişkilidir (Pareja et al., 2020; Seo et al., 2018).




Şekil 3. Zamanla değişen ve statik grafik türlerinin karşılaştırılması.

Her model, aynı veri ön işleme ve eğitim koşulları altında ayrı ayrı eğitilecek ve performans metrikleri (Accuracy, Macro-F1, Precision, Recall, ROC-AUC) üzerinden karşılaştırılacaktır.

TGAT'in kısa vadeli zamansal örüntüleri yakalamadaki başarısı, GCLSTM'in uzun sekanslı bağımlılıkları modelleme yeteneği ve hibrit modelin iki yaklaşımı birleştirme potansiyeli analiz edilerek, hangi mimarinin sistem için en uygun olduğu deneysel olarak belirlenecektir.

Her modelin son katmanından elde edilen zamansal gömüler (temporal embeddings), iki katmanlı bir Çok Katmanlı Algılayıcı (Multi-Layer Perceptron (MLP)) sınıflandırıcıya aktarılacaktır.

Bu sınıflandırıcı, 15 saldırı türü için olasılık dağılımı Yumuşak Maksimum Fonksiyonu (Softmax) (Al-Haija et al., 2025) üreterek nihai tahmini yapacaktır.



Şekil 4. Önerilen sistemin model akış şeması.

Ayrıca, zaman pencereleri boyunca elde edilen tahmin sonuçları üzerinde regresyon analizi uygulanarak geçmiş saldırı örüntülerinden gelecekteki eğilimler çıkarılacaktır.

Bu sayede model yalnızca mevcut saldırı türlerini sınıflandırmakla kalmayacak, aynı zamanda zamansal eğilim analizi (trend forecasting) yoluyla olası gelecekteki saldırı yoğunluklarını da öngörebilecektir.

TGAT, GCLSTM ve hibrit mimarilerin kodlanması ve PyTorch ortamında eğitime hazır hale getirilmesi, çalışma takviminde “Model Geliştirme” olarak tanımlanan ikinci aşamada gerçekleştirilecektir. Bu aşamada model hiperparametreleri belirlenecek ve ilk eğitim döngüleri tamamlanacaktır.


Eğitim sürecinde,

- Stratified k-Fold (5 katlı) ve Temporal Hold-out stratejileri birlikte uygulanacaktır.
- Kayıp fonksiyonları: Class-weighted CrossEntropy ve gerekirse Focal Loss kombinasyonu.
- Optimizasyon: AdamW, başlangıç öğrenme oranı $1e-3$, dropout 0.3, batch size 64–128 (donanımına göre ayarlanacak).
- Hiperparametre seçimi: Optuna ile otomatik arama (embedding boyutu, attention head sayısı, seq_len vb.).
- Performans metrikleri: Accuracy; Macro F1-score (ana kriter); Precision & Recall (sınıf bazlı); ROC-AUC (çoklu sınıf ayırım gücü).
- Temporal Ablation: zaman damgalarının karıştırıldığı (timestamp shuffle) testlerde performans düşüşü ile zaman faktörünün etkisi nicel olarak ölçülecektir (İbrahim et al., 2025).

4. Deneysel Sınama Ortamı (Testbed)

4.1. Testbed Yapısı: Prototip deneyleri izole bir laboratuvar sınama ortamında yürütülecektir. Sınama ortamı bileşenleri (Şekil 4):

- Raspberry Pi (inference & sensor) — gerektiğinde inline proxy/firewall veya passive network sensor olarak konumlandırılacaktır;
- Victim PC (Kurban Bilgisayar);
- Attacker PC (Saldıran Bilgisayar);
- Management PC (Yönetici Bilgisayar) (GPU destekli, ör. RTX 3060 / Apple M3).



Şekil 5. İzole laboratuvar sinama ortamı.

Ağ trafiği, yansıtılmış port (port mirroring) veya ağ erişim noktası (TAP) aracılığıyla Raspberry Pi sensörüne aktarılacaktır. Deneyler tekrar edilebilir betikler ile otomatikleştirilecek; paket kayıt (pcap) ve akış logları LSM2024 formatına uygun şekilde ön işlemden geçirilip kayan pencere (sliding-window) / grafik dönüşümü ile modele girdi olarak verilecektir (Al-Haija et al., 2025). Uygulanan yöntem, akademik olarak güçlü bir yapıya sahip olup aynı zamanda sanayi uygulamalarına doğrudan aktarılabilir niteliktedir; geliştirilen modelin bankacılık ve üniversite altyapılarında kullanılabilirliği bu yöntem aracılığıyla test edilecektir.

4.2. Saldırı Üretim Süreci: Her saldırı türü için parametrelenmiş betikler hazırlanacaktır (pps, süre, hedef IP/port vb.). Senaryolar: DDoS (SYN/UDP/ICMP), SSH brute-force, Slowloris/slow HTTP, port taramaları (nmap), SQL Injection/XSS, C2 callback davranışları. Denemeler tekil ve kombine koşullarda çalıştırılarak modelin dayanımı ölçülür; tüm saldırılar sadece izole sinama ortamına yönlendirilecektir.

5. Uygulama ve Optimizasyon

Model geliştirme PyTorch Geometric veya DGL kütüphaneleri kullanılarak yapılacaktır. Dağıtım aşamasında, iki farklı yol denenecektir:

1. TorchScript (script) formatı kullanılarak torch.jit.load ile Raspberry Pi üzerinde inference,
2. Doğrudan PyTorch Python runtime üzerinden inference.

Kullanım kolaylığı, performans ve proje hedefleri açısından en mantıklı ve kararlı yol belirlenip o yöntemle devam edilecektir. Ölçülecek metrikler: inference latency (p50/p95/p99), throughput (windows/s), bellek kullanımı. Optimizasyon adımları: post-training quantization (8-bit), micro-batching, model pruning ve uygun thread ayarları olarak düşünülmektedir. Bu adımlar, gerçek zamanlı ağ entegrasyonu (pfSense / Snort / Suricata) öncesinde sistemin kararlılığını ve verimliliğini arttırmayı amaçlamaktadır.

Deneyisel olarak, zaman penceresi uzunluklarının (1s, 5s, 10s) etkisi, düğüm/kenar özelliklerinin önemi, TGAT, GCLSTM ve hibrit TGAT-GCLSTM etkisi detaylı analiz edilecektir (Dai et al., 2024; Pareja et al., 2020).

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmacının başarısına katkısı “Çalışma Takvimi” doldurulurak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmacının Başarısına Katkısı***
28/09/2025-.28/11/2025	Altyapı, veri ön işleme	Buğra Muhçi, Emre Dumbo	%100, %15
28/11/2025-.30/01/2026	Model geliştirme	Emre Dumbo	%85, %25
30/01/2026-.28/02/2026	Optimizasyon	Buğra Muhçi, Emre Dumbo	%90, %10
01/03/2026-.31/03/2026	Model aktarımı ve entegrasyonu	Buğra Muhçi, Emre Dumbo	%100, %10
01/04/2026-.25/04/2026	Kuantizasyon / Pi 5 testi	Buğra Muhçi	%100, %10
25/04/2026-.30/06/2026	PoC testleri, KPI analizi	Buğra Muhçi, Emre Dumbo	%90, %15
01/07/2026-.28/08/2026	Sistem testi ve performans doğrulaması	Buğra Muhçi, Emre Dumbo	%90, %15

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.

(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

3.2 Risk Yönetimi

Araştırmacının başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmacının başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmacının temel hedeflerinden saptmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
Zamansal graf tabanlı modeller, özellikle kısa zaman pencerelerinde (ör. 1–5 sn) benzer trafiği kötü niyetli olarak etiketleyebilir. Bu durum, normal ağ davranışlarının yanlışlıkla	- Güven skoru (confidence) tabanlı eşik değeri (threshold) stratejisi uygulanacaktır. - Alarm tetikleme için ≥ 10 yüksek güven skorlu olayın (confidence ≥ 0.95) aynı

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

saldırı olarak değerlendirilmesine (false positive) yol açabilir.	hedef/sınıf içinde olması koşulu aranacaktır. Model değerlendirmesinde Precision-Recall dengesi optimize edilerek alarm doğruluğu artırılacaktır.
LSNM2024 veri kümesinde saldırı sınıfları arasında ciddi dengesizlik (ör. SQLi vs DDoS) bulunması, modelin belirli sınıflarda düşük doğrulukla çalışmasına neden olabilir. Bu durum, sistemin azınlık saldırı türlerini kaçırmaya (false negative) yol açabilir.	- SMOTE ve class-weighted loss fonksiyonları kullanımıyla veri dengesinin sağlanması. - F1-makro ve per-class precision izlenerek modelin yeniden eğitimi. - Threshold-temelli alarm stratejisi (≥ 10 yüksek güven skorlu olay) ile gürültü azaltımı.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Eskişehir Teknik Üniversitesi - Bilgisayar Laboratuvarı	Proje kapsamında Raspberry Pi'nin ağ bağlantısı, trafik yönlendirme (proxy/firewall) konfigürasyonu ve veri toplama işlemleri bu laboratuvar ortamında gerçekleştirilecektir. Laboratuvar, yönetilebilir switch, test ağı altyapısı ve güvenli izolasyon imkanı sağlamaktadır.
Kişisel - Raspberry Pi 5 (8 GB RAM, 128 GB SD kart)	Ağ trafiğini gerçek zamanlı olarak izleme, saldırı tespiti modeli (inference) çalıştırma, pcap dosyalarını toplama ve ön işleme görevlerini yürütmek için kullanılacaktır. Ayrıca kullanıcı etkileşimli prototip (internet bağlantısını kesme/izleme) arayüzü bu cihaz üzerinde çalışacaktır.
Kişisel - GPU Destekli Yönetim İstasyonu (NVIDIA RTX 3060 / 6 GB VRAM)	Model eğitimi, hiperparametre optimizasyonu, ablation çalışmaları ve TGAT/GCLSTM modellerinin performans analizleri için kullanılacaktır. Eğitim sonrası Raspberry Pi üzerinde çıkarım yapılmak üzere optimize edilmiş modeller bu sistemde üretilcektir.
Kişisel - Apple MacBook M3 (Yerel Test Ortamı)	Eğitim verilerinin işlenmesi, kod geliştirme (PyTorch Geometric, DGL), model doğrulama ve küçük ölçekli deneysel testlerin yürütülmesinde kullanılacaktır.

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	Proje sonucunda elde edilecek bulguların IEEE, Springer veya Elsevier indeksli konferans ve dergilerde (ör. <i>IEEE ICMLCN, Computers & Security, Expert Systems with Applications</i>) yayımlanması hedeflenmektedir. Modelin teknik detayları, "Temporal Graph Neural Networks for Intrusion Detection" başlıklı bir bilimsel makale formatında sunulacaktır. Ayrıca proje kapsamında geliştirilen kod tabanı, veri işleme boru hattı (pipeline'ı) ve deneysel sonuçlar açık kaynak olarak GitHub üzerinden paylaşılacak, akademik yeniden üretilebilirlik (reproducibility) ilkelerine katkı sağlayacaktır.
Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	Proje sonunda, Raspberry Pi üzerinde çalışan bir "akıllı güvenlik modülü" prototipi geliştirilecektir. Bu prototip, küçük ve orta ölçekli ağlarda (ör. banka şubeleri, eğitim kurumları, kampüs ağları gibi yüksek erişim trafiğine sahip kurumlarda) gerçek zamanlı saldırı tespiti sağlayan yerli bir savunma sistemi olarak değerlendirilebilecektir. Modelin çıkarım (inference) mekanizması, düşük maliyetli donanım üzerinde çalışabilmesi sayesinde Türkiye'nin yerli siber güvenlik ekosistemine kolayca entegre edilebilecek esnek ve ölçeklenebilir bir yapı sunmaktadır. Proje çıktıları aynı zamanda, öğrenciler ve araştırmacılar için graf tabanlı yapay zeka sistemlerinin güvenlik alanında uygulanmasına dair açık kaynak bir eğitim materyali niteliği taşıyacaktır. Ayrıca sistem, ilerleyen süreçte pfSense / Suricata veya benzeri gibi güvenlik araçlarıyla entegrasyonu ile saha testlerine genişletilerek bankacılık ve üniversite altyapılarında doğrulanabilir; bu sayede ticarileşmeye aday bir ürün haline getirilebilir. Proje; teknolojik altyapı, yapay zeka ve siber güvenlik alanındaki yenilikçi yaklaşımıyla Birleşmiş Milletler Sürdürülebilir Kalkınma Amaçları'ndan (SKA) 9. hedef olan "Sanayi, Yenilikçilik ve Altyapı" (Industry, Innovation and Infrastructure) amacına doğrudan katkı sağlamaktadır (kureselamaclar.org). Geliştirilecek bu yerli, düşük maliyetli ve ölçeklenebilir güvenlik modülü, yenilikçi altyapıların güçlendirilmesi, endüstriyel siber güvenliğin desteklenmesi ve yerli teknolojik kapasitenin artırılması yönünde sürdürülebilir bir sanayi katkısı sunacaktır.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	Bu proje sonucunda elde edilen teknik bilgi ve deneyim, TÜBİTAK 1001 veya 1512 (BİGG) programlarına temel oluşturabilecek yeni araştırma konularının (ör. <i>Real-time Edge AI for Cyber Defense, Federated Intrusion Detection via Graph Neural Networks</i>) geliştirilmesine katkı sağlayacaktır. Ayrıca proje, Avrupa Birliği Horizon Europe – Secure and Trusted AI Systems çağrılarını kapsamında yürütülen uluslararası araştırma konsorsiyumlarına katılım potansiyeli taşımaktadır.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

Senkron Siber Güvenlik Yazılım ve Bilişim Çözümleri A.Ş., proje kapsamında teknik mentorluk, sektör bilgisi ve gerekli altyapı desteğini sağlamayı **kabul etmiştir**. Şirket daha önce TÜBİTAK destekli bir projede yer almadığı için 2209-B Programı çerçevesinde ortak başvuru yapılamamıştır. Ancak firma, 2209-A kapsamında yürütülecek bu çalışmaya **resmî olarak destek vermeye devam edeceğini**, proje süresince bilgi paylaşımı ve danışmanlık sağlayacağını belirtmiştir.

6. EKLER

EK-1: KAYNAKLAR

- Al-Haija, Q. A., Masoud, Z., Yasin, A., Alesawi, K., & Alkarnawi, Y. (2024a). Revolutionizing Threat Hunting in Communication Networks: Introducing a Cutting-Edge Large-Scale Multiclass Dataset. In *2024 15th International Conference on Information and Communication Systems (ICICS)* (pp. 1-5). IEEE.
- Al-Haija, Q. A., Masoud, Z., Yasin, A., Alesawi, K., & Alkarnawi, Y. (2024b). Large-Scale Network Cyberattacks Multiclass Dataset 2024 (LSNM2024), Mendeley Data, V1, doi: 10.17632/7pzyfvv9jn.1
- Al-Haija, Q. A., Masoud, Z., Yasin, A., Alesawi, K., & Alkarnawi, Y. (2025). End-to-End Threat Hunting with a Novel Multiclass Dataset for Intelligent Intrusion Detection. *Authorea Preprints*.
- Bharathi, P. S., & Raj, M. M. (2025, June). Graph neural networks for intrusion detection in next-generation 6G networks: a cybersecurity perspective. In *2025 6th International Conference on Intelligent Communication Technologies and Virtual Mobile Networks (ICICV)* (pp. 1306-1312). IEEE.
- Birleşmiş Milletler Kalkınma Programı (UNDP). (2025). "Sürdürülebilir Kalkınma Amaçları", United Nations Development Program, Türkiye. <https://turkiye.un.org/tr/sdgs>, Son erişim tarihi: 11 Kasım 2025.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of artificial intelligence research*, 16, 321-357.
- Cobos, E. V., Cakir, S., Straub, S., Qiang, C. Z., & Torgusson, C. (2024). A review of the economic costs of cyber incidents. Washington, DC: World Bank.
- Dai, C., Tang, Q., & Ding, H. (2024, July). TGAT: temporal graph attention network for blockchain phishing scams detection. In *2024 International Conference on Computer, Information and Telecommunication Systems (CITS)* (pp. 1-7). IEEE.
- IBM. (2024). "Escalating Data Breach Disruption Pushes Costs to New Highs", Son erişim: 15 Kasım 2025. <https://newsroom.ibm.com/2024-07-30-ibm-report-escalating-data-breach-disruption-pushes-costs-to-new-highs>
- Ibrahim, A. S. T., Paolini, E., Cugini, F., & Paolucci, F. (2025, May). Real-Time Graph Neural Network for Malicious Traffic Detection. In *2025 IEEE International Conference on Machine Learning for Communication and Networking (ICMLCN)* (pp. 1-6). IEEE.
- Khraisat, A., Gondal, I., Vamplew, P., & Kamruzzaman, J. (2019). Survey of intrusion detection systems: techniques, datasets and challenges. *Cybersecurity*, 2(1), 1-22.
- Kipf, T. N. (2016). Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*.
- Kose, H. T., Nunez-Yanez, J., Piechocki, R., & Pope, J. (2024). A survey of computationally efficient graph neural networks for reconfigurable systems. *Information*, 15(7), 377.
- Pareja, A., Domeniconi, G., Chen, J., Ma, T., Suzumura, T., Kanezashi, H., ... & Leiserson, C. (2020, April). Evolvegc: Evolving graph convolutional networks for dynamic graphs. In *Proceedings of the AAAI conference on artificial intelligence* (Vol. 34, No. 04, pp. 5363-5370).
- Ring, M., Wunderlich, S., Scheuring, D., Landes, D., & Hotho, A. (2019). A survey of network-based intrusion detection data sets. *Computers & Security*, 86, 147-167.
- Rossi, E., Chamberlain, B., Frasca, F., Eynard, D., Monti, F., & Bronstein, M. (2020). Temporal graph networks for deep learning on dynamic graphs. *arXiv preprint arXiv:2006.10637*.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

- Sankar, A., Wu, Y., Gou, L., Zhang, W., & Yang, H. (2020, January). Dysat: Deep neural representation learning on dynamic graphs via self-attention networks. In *Proceedings of the 13th international conference on web search and data mining* (pp. 519-527).
- Seo, Y., Defferrard, M., Vandergheynst, P., & Bresson, X. (2018, November). Structured sequence modeling with graph convolutional recurrent networks. In *International conference on neural information processing* (pp. 362-373). Cham: Springer International Publishing.
- Söhner, E., Helm, M., & Jaeger, B. (2020). Temporal Graph Neural Networks. *School of Computation, Information and Technology, Technical University of Munich, Chair of Network Architectures and Services*.
- T.C. Cumhurbaşkanlığı Strateji ve Bütçe Başkanlığı (CSBB). (2023). 12. Kalkınma Planı (2024-2028). Ankara: CSBB.
https://www.sbb.gov.tr/wp-content/uploads/2023/12/On-Ikinci-Kalkinma-Plani_2024-2028_11122023.pdf, Son erişim tarihi: 11 Kasım 2025
- T.C. Sanayi ve Teknoloji Bakanlığı (STB). (2025a). 2030 Sanayi ve Teknoloji Stratejisi. Ankara.
<https://www.sanayi.gov.tr/plan-program-raporlar-ve-yayinlar/strateji-belgeleri/mu2103011621>, Son erişim tarihi: 11 Kasım 2025.
- T.C. Sanayi ve Teknoloji Bakanlığı (STB). (2025b). 2030 Sanayi ve Teknoloji Stratejisi: Öncelikli Program ve Projeler. *Anahtar Dergisi*, 37(436), 15–25. https://edergi.sanayi.gov.tr/File/Journal/2025/4/4_2025.pdf, Son erişim tarihi: 11 Kasım 2025.
- T.C. Sanayi ve Teknoloji Bakanlığı (STB). (2025c). *Geleceğin Yapay Zeka Teknolojileri (GYZT) Odak Teknoloji Ağı (OTAĞ): OTAĞ Sonuç Raporu*. Ankara.
https://arge.ssb.gov.tr/TeknolojiYolHaritalari/PublishingImages/Sayfalar/GYZT%20OTA%C4%9E/GYZT_OTAG_Sonuc_Raporu.pdf Son erişim tarihi: 11 Kasım 2025.
- Taylor, S. A., Fernandez-Marques, J., & Lane, N. D. (2020). Degree-quant: Quantization-aware training for graph neural networks. *arXiv preprint arXiv:2008.05000*.
- Xu, D., Ruan, C., Korpeoglu, E., Kumar, S., & Achan, K. (2020). Inductive representation learning on temporal graphs. *arXiv preprint arXiv:2002.07962*.